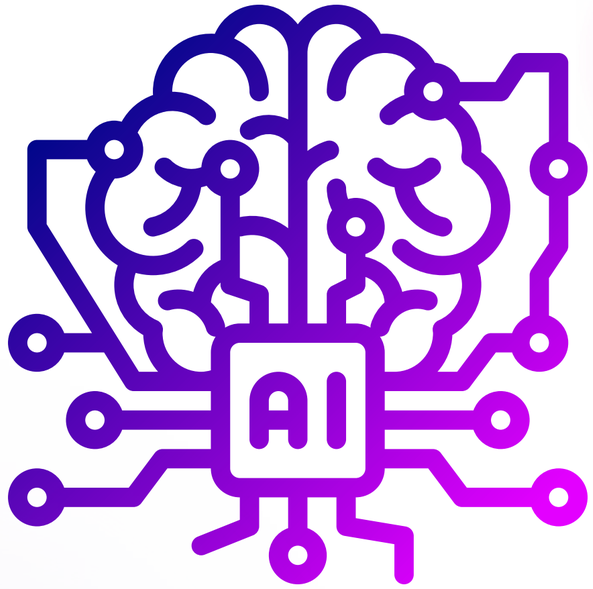

INTELIGENCIA ARTIFICIAL

TRUJILLO ACOSTA BRYANT
MENDOZA GARCIA BRAYAN

Enfoque Conexionista

Se basa en redes neuronales artificiales inspiradas en el cerebro humano. Este enfoque es capaz de aprender de datos y adaptarse a nuevas situaciones. Se ha utilizado con éxito en aplicaciones como el reconocimiento de imágenes y el procesamiento del lenguaje natural

Ejemplo utilizando el paradigma conexionista

Descripción

El ejemplo utiliza una red neuronal simple para aprender la relación matemática entre temperaturas en grados Celsius y Fahrenheit. Este modelo se basa en el paradigma del conexionismo, que busca emular el funcionamiento del cerebro humano mediante redes de nodos interconectados (neuronas artificiales). El objetivo es entrenar una red neuronal para predecir temperaturas en Fahrenheit a partir de valores en Celsius, sin necesidad de programar explícitamente la fórmula

Datos de entrenamiento: Se proporcionan dos arreglos de NumPy con valores de Celsius y sus equivalentes en Fahrenheit

Modelo: Se construye una red neuronal simple con una sola capa densa (Dense) de una neurona, utilizando TensorFlow y Keras. Esta capa tiene un solo peso (pendiente) y un sesgo (intercepción).

Entrenamiento: El modelo se entrena durante 1000 épocas utilizando el optimizador Adam y la función de pérdida de error cuadrático medio (mean_squared_error), ajustando los pesos para minimizar la diferencia entre las predicciones y los valores reales.

Realizando una Predicción

Una vez entrenado el modelo, podemos hacer una predicción. En este caso, convertiremos **180 grados Celsius** a Fahrenheit usando nuestra red neuronal.

```python
print("Hagamos una predicción!")
resultado = modelo.predict(np.array([[180.0]]))
print("El resultado es " + str(resultado) + " fahrenheit!")
```

Python

```
Hagamos una predicción!
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 33ms/step
El resultado es [[355.5985]] fahrenheit!
```

Predicción: Una vez entrenado, el modelo predice el valor en Fahrenheit para 180°C, resultando en aproximadamente 355.6°F (cercano al valor real de 356°F).

Podemos inspeccionar los **pesos internos** de la capa de nuestra red neuronal. Esto nos permite entender cómo el modelo ha aprendido la relación entre los grados Celsius y Fahrenheit.
Peso (Weight): Representa la pendiente de la relación aprendida.
Sesgo (Bias): Representa el ajuste adicional aplicado a la salida del modelo.

```python
print("variables internas del modelo")
print(capa.get_weights())
```

Python

```
variables internas del modelo
[array([[1.7981906]], dtype=float32), array([31.92421], dtype=float32)]
```

Análisis: Se visualiza la disminución de la pérdida durante el entrenamiento y se inspeccionan los pesos internos del modelo (pendiente ≈ 1.8 y sesgo ≈ 31.9) que aproximan la formula que es
Formula = 9/5 C + 32
9/5 es igual a 1.8 y 32 seria el sesgo

Aplicación del Conexionismo en el Ejemplo

- Unidades: Una neurona procesa Celsius para predecir Fahrenheit mediante una combinación lineal (peso y sesgo).
- Conexiones: El peso y sesgo se ajustan durante el entrenamiento con el optimizador Adam.
- Aprendizaje Supervisado: Usa ejemplos (Celsius-Fahrenheit) para minimizar el error.
- Distribución del Conocimiento: La relación se aprende en los pesos, no en reglas explícitas.
- Generalización: Predice valores no vistos (ej. 180°C ≈ 355.6°F).
- Resumen: Emula el aprendizaje humano al inferir patrones de datos sin reglas predefinidas.

Limitaciones y Beneficios del Conexionismo en el Ejemplo

BENEFICIO

- **Aprendizaje automático:** Aprende la relación Celsius-Fahrenheit sin codificar la formula
- **Predice valores no vistos** (ej. 180°C ≈ 355.6°F).
- **Maneja datos ruidosos o imperfectos.**
- **Simplicidad conceptual:** Modelo de una neurona como introducción accesible al conexionismo.

LIMITACIÓN

- **Sobrecomplejidad:** Red neuronal innecesaria para un problema simple con fórmula conocida
- **Dependencia de datos:** Requiere datos suficientes; con solo 7 pares, la precisión puede ser limitada.
- **Falta de precisión:** Aproxima la relación (ej. 355.6°F vs. 356°F real para 180°C).
- **Costo computacional:** 1000 épocas consumen recursos, injustificados para un problema simple.
- **Falta de interpretabilidad:** Pesos y sesgo no explican claramente el aprendizaje, a diferencia de la fórmula.
- **Limitación a linealidad:** Solo modela relaciones lineales; no sirve para problemas no lineales sin ajustes.

PROCESO DE APRENDIZAJE AUTOMÁTICO

1.-ADQUISICIÓN DE DATOS

La adquisición de datos es el primer paso en el proceso de aprendizaje automático. Se refiere al acto de reunir y recopilar información relevante de diversas fuentes, tanto internas como externas. Pueden provenir de bases de datos, sensores, encuestas, etc.

2.-PROCESAMIENTO DE DATOS

Limpieza, normalización y transformación de los datos para que sean adecuados para el modelo. Incluye eliminar datos faltantes o inconsistentes.

3.-ENTRENAMIENTO DE MODELO

Los datos de entrenamiento deben contener la respuesta correcta, que se conoce como destino o atributo de destino. El algoritmo de aprendizaje encuentra patrones en los datos de entrenamiento que asignan los atributos de los datos de entrada al destino (la respuesta que desea predecir) y genera un modelo de ML que captura dichos patrones.

4.-EVALUACIÓN DEL MODELO

Medición del rendimiento del modelo con métricas como precisión, error o pérdida, usando datos de prueba o validación. El objetivo principal es garantizar que el modelo funciona satisfactoriamente en condiciones reales y que es capaz de generalizar correctamente más allá de los datos de entrenamiento.

5.-IMPLEMENTACIÓN DEL MODELO

La implementación del modelo es el paso donde un modelo ya entrenado se integra en un sistema o aplicación para realizar predicciones en el mundo real.

Similitudes y Diferencias entre el Modelo Cognitivo y el Aprendizaje Automático

Similitudes

- **Procesamiento de información:** Ambos procesan datos (sensoriales en el humano, digitales en ML).
- **Aprendizaje y adaptación:** Los dos mejoran su rendimiento con el tiempo basándose en la experiencia.
- **Toma de decisiones:** Tanto los modelos cognitivos como los modelos de ML buscan hacer predicciones o inferencias.
- **Generalización del conocimiento:** Ambos buscan aplicar lo aprendido en situaciones nuevas.

Diferencias

- **Adquisición de Datos:** En aprendizaje automático, los datos son explícitos y estructurados; en el modelo cognitivo, los estímulos pueden ser subjetivos y sensoriales.
- **Procesamiento de Datos:** El aprendizaje automático usa algoritmos predefinidos; el procesamiento cognitivo humano es más flexible y adaptativo.
- **Entrenamiento:** En aprendizaje automático, el ajuste es matemático y depende de datos; en cognición, el aprendizaje es continuo y basado en experiencias diversas.
- **Evaluación:** El aprendizaje automático usa métricas cuantitativas (ej. error); el modelo cognitivo depende de juicios subjetivos o pruebas psicológicas.
- **Implementación:** En aprendizaje automático, el modelo se despliega en sistemas; en cognición, las acciones son ejecutadas por el individuo en contextos variados.

Paradigma Simbolico

Es un enfoque que representa el conocimiento mediante símbolos y reglas lógicas para manipular esos símbolos. Se basa en la idea de que el razonamiento puede modelarse mediante estructuras simbólicas y reglas de inferencia.

Diagnóstico médico con MYCIN

Desarrollado en la década de 1970 en la Universidad de Stanford, MYCIN fue un sistema experto diseñado para diagnosticar infecciones bacterianas en la sangre y recomendar tratamientos con antibióticos.

MYCIN tenía una base de datos con cientos de reglas del tipo:
"Si el paciente tiene fiebre alta y los cultivos de sangre muestran bacterias gramnegativas, entonces existe una probabilidad de X% de infección por meningitis bacteriana."

Diagnóstico médico con MYCIN

MYCIN no solo diagnosticaba, sino que también sugería antibióticos y dosis específicas, basándose en reglas definidas por expertos médicos con Uso de heurísticas y reglas de decisión

- Motor de inferencia
- Utilizaba encadenamiento hacia atrás (backward chaining) para hacer preguntas y llegar a un diagnóstico.
- Ejemplo de diálogo con el médico:
  - ¿El paciente tiene fiebre? → Sí
  - ¿Los cultivos de sangre muestran bacterias gramnegativas? → Sí
  - ¿Hay rigidez en el cuello? → Sí
  - Conclusión: Probabilidad alta de meningitis bacteriana.

Beneficios

- 1️⃣ Explicabilidad: Podía justificar sus decisiones mostrando las reglas usadas.
- 2️⃣ Precisión: Basado en conocimientos médicos estructurados.
- 3️⃣ Razonamiento lógico: Usaba reglas para diagnosticar y recomendar tratamientos.
- 4️⃣ No dependía de grandes datos: No necesitaba entrenarse con miles de casos.

Limitaciones

- 1️⃣ No aprendía automáticamente: Requería que expertos añadieran reglas manualmente.
- 2️⃣ Difícil de escalar: Muchas reglas hacían que el sistema fuera complicado de mantener.
- 3️⃣ Rigidez: No podía manejar casos imprevistos o síntomas combinados.
- 4️⃣ Interacción limitada: No procesaba lenguaje natural de forma flexible.

¿Por qué se dejó de usar? Problemas legales, falta de aceptación en hospitales y la llegada de IA basada en Machine Learning.

Hoy en día, el paradigma simbólico sigue usándose en IA explicable (XAI) y sistemas de toma de decisiones.

GRACIAS